

Modelo Predictivo

Fuga de Clientes en Telefonía

Integrantes

- Fernando Carcamo
- Hugo Smith
- Johny Linco
- Tanya Moya

Proyecto 1, Ciencia de Datos y sus Aplicaciones

03.10.2023

Introducción




En un mercado de telecomunicaciones altamente competitivo, donde la retención de clientes es esencial para el éxito empresarial, nos enfrentamos al desafío de prever y mitigar la fuga de clientes. Para ello se requiere un:

"Modelo Predictivo de Fuga de Clientes"

Nuestro objetivo principal es construir un modelo de aprendizaje automático que nos permita anticipar si un cliente está en riesgo de abandonar nuestros servicios de telefonía celular. Esto no solo nos ayudará a reducir la pérdida de clientes, sino que también nos permitirá tomar medidas proactivas para mantener a nuestros clientes satisfechos y leales.

Antecedentes y Metodología

Contamos con un conjunto de datos robusto que abarca 6,590 registros, que representan el comportamiento de nuestros clientes. Nuestra variable objetivo es "Fugado", que nos indica si un cliente ha decidido abandonar nuestros servicios en un período de un mes.



**Limpieza y
preparación de
datos**

Garantizaremos que nuestros datos sean confiables y estén listos para el análisis.

**Análisis
exploratorio y
División de datos**

Exploraremos las relaciones y patrones en nuestros datos para identificar factores clave relacionados con la fuga de clientes. Realizamos división de datos entre entrenamiento y prueba.

Modelado

Aplicaremos algoritmos de aprendizaje automático para construir un modelo predictivo.

**Validación del
modelo**

Evaluaremos la precisión y la robustez de nuestro modelo para asegurarnos de que sea confiable y útil.

Limpieza y preparación de datos


En esta etapa nos enfocamos en garantizar que los datos estén en condiciones óptimas para entrenar y evaluar el modelo.

Iniciamos con la separación de los datos en dos grupos distintos: uno que contiene ejemplos de clientes que han "fugado" y otro que contiene ejemplos de clientes que "no han fugado".



El propósito principal de esta separación consistía en verificar el **balanceo de clases**, es decir, determinar si hay una proporción adecuada de ejemplos en ambas categorías (fugados y no fugados). Un desequilibrio en las clases puede llevar a problemas de sesgo en el modelo, donde el modelo podría ser bueno para predecir una clase, pero no la otra debido a la falta de datos de entrenamiento.

El desbalance se abordó realizando un re-balanceo de las clases, reduciendo la cantidad de ejemplos de la clase más masiva, en este caso Clientes no Fugados. Se eligió un balanceo de un 30% más de ejemplos de la clase mayoritaria.



Análisis exploratorio y División de datos

En esta etapa hemos explorado la data y definido nuestros grupos de entrenamiento y prueba.

Datos de Entrenamiento

70%
3.008

Son un subconjunto de los datos totales que se utilizan para "enseñar" o "entrenar" al modelo.
En este caso, registros de clientes pasados con la información sobre si abandonaron o no el servicio (variable "Fugado").

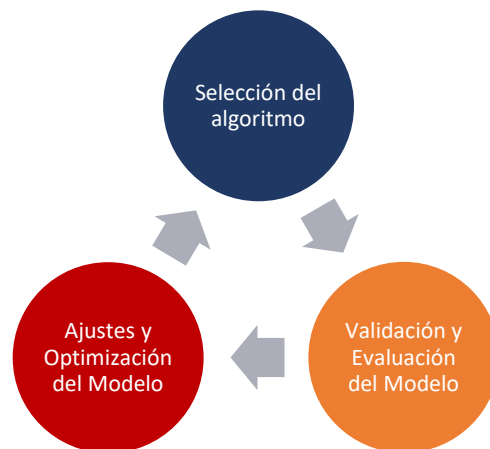
Datos de Prueba

30%
1.290

Los datos de prueba son otro subconjunto de los datos totales que el modelo no ha visto durante el entrenamiento.
Estos datos se utilizan para evaluar el rendimiento del modelo después de que ha sido entrenado.
El objetivo es evaluar la capacidad del modelo para generalizar y hacer predicciones precisas en datos nuevos y no vistos previamente.

Modelado

En nuestro Caso el Algoritmo seleccionado para nuestro modelo corresponde a un
ARBOL DE CLASIFICACIÓN.



Dentro de los ajustes para llegar al modelo óptimo verificamos la simpleza del modelo en cuanto a la profundidad de este, pero sin sacrificar la precisión del mismo, adicional a las pruebas con exclusión de variables, buscando el mejor resultado tanto en entrenamiento como en pruebas.

Datos de Entrenamiento

```
> DT_predict_train <- predict(DT_model, training.data, type = "class")
> confusionMatrix(DT_predict_train, as.factor(training.data$Fugado), positive="Si")
Confusion Matrix and Statistics

      Reference
Prediction No  Si
No  1469  260
Si   216 1063

      Accuracy : 0.8418
      95% CI   : (0.8282, 0.8546)
No Information Rate : 0.5602
P-Value [Acc > NIR] : < 2e-16

      Kappa : 0.6777

McNemar's Test P-Value : 0.04874

      Sensitivity : 0.8035
      Specificity : 0.8718
      Pos Pred Value : 0.8311
      Neg Pred Value : 0.8496
      Prevalence : 0.4398
      Detection Rate : 0.3534
      Detection Prevalence : 0.4252
      Balanced Accuracy : 0.8376

      'Positive' Class : Si
```

Datos de Prueba

```
> DT_predict_test <- predict(DT_model, testing.data, type = "class")
> confusionMatrix(DT_predict_test, as.factor(testing.data$Fugado), positive="Si")
Confusion Matrix and Statistics

      Reference
Prediction No  Si
No   641  107
Si   103  439

      Accuracy : 0.8372
      95% CI   : (0.8159, 0.857)
No Information Rate : 0.5767
P-Value [Acc > NIR] : <2e-16

      Kappa : 0.6662

McNemar's Test P-Value : 0.836

      Sensitivity : 0.8040
      Specificity : 0.8616
      Pos Pred Value : 0.8100
      Neg Pred Value : 0.8570
      Prevalence : 0.4233
      Detection Rate : 0.3403
      Detection Prevalence : 0.4202
      Balanced Accuracy : 0.8328

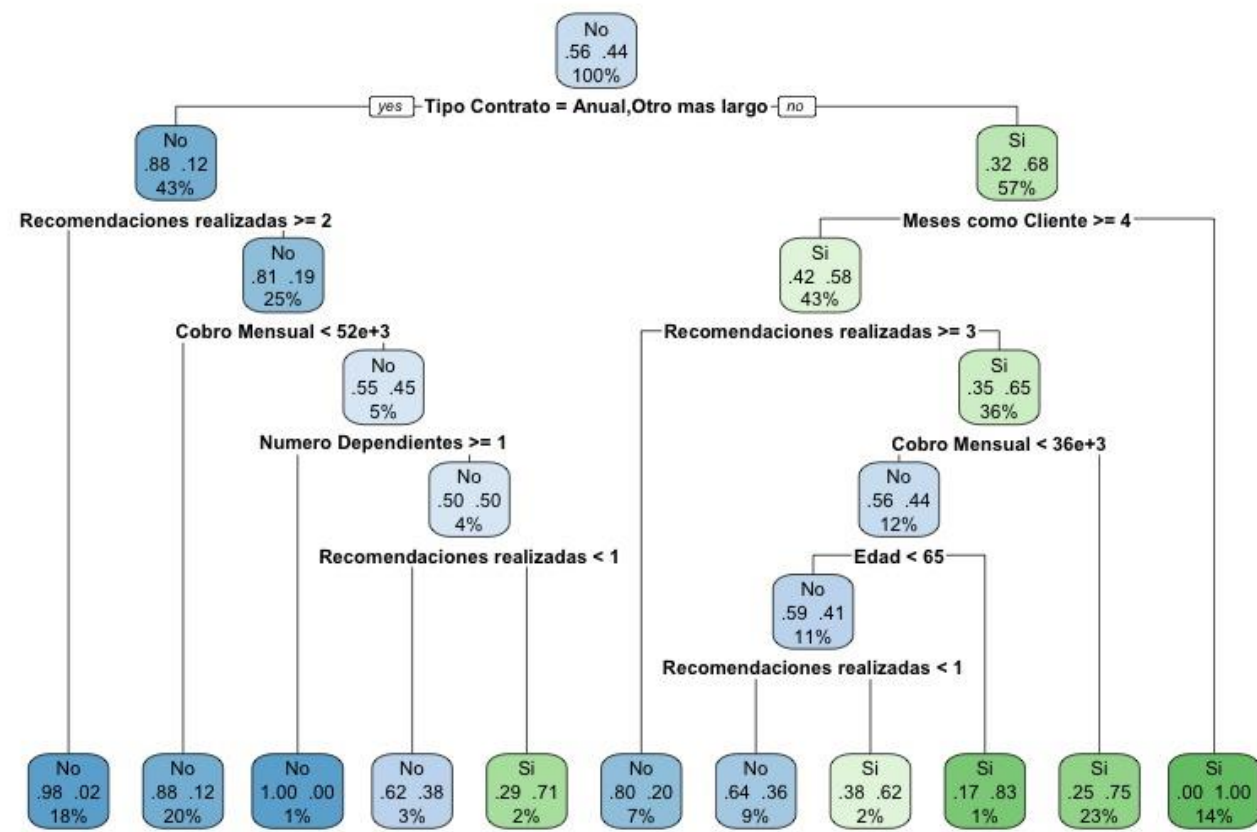
      'Positive' Class : Si
```

Árbol de Clasificación Final

El Árbol de Clasificación aplicado presenta una precisión de un 84%.

La sensibilidad del modelo alcanza un 80%, pero la especificidad del modelo alcanza un 87%, que representa la capacidad de evitar falsos negativos.

Parámetro	Entrenamiento	Test
Acuracy	84,2%	83,7%
Sensitivity	80,4%	80,4%
Specificity	87,2%	86,2%



Patrones de fuga detectados.

Identificamos a los clientes en riesgo con anticipación, lo que nos permitirá tomar medidas preventivas

El objetivo es reducir la fuga de clientes y, en consecuencia, aumentar la retención y la rentabilidad.



Acciones de retención a partir de los patrones de fuga detectados

18%

Las acciones propuestas, promueven una reducción de un 18% de los clientes que tienden a fugarse

1. Programas de Lealtad

Crear un programa de lealtad en el que los clientes acumulen puntos o recompensas por cada mes que permanezcan como cliente. Estos puntos pueden canjearse por descuentos, regalos o servicios adicionales.

Ofrecer a los clientes leales actualizaciones gratuitas de sus dispositivos o planes, así como acceso a contenido exclusivo, como películas, música o eventos deportivos.

2. Descuentos a Largo Plazo

Ofrecer descuentos adicionales a aquellos clientes que renueven su contrato anual. Esto les brindará un incentivo adicional para permanecer como cliente durante más tiempo.

3. Programa de Recompensas por Referidos

Ofrecer incentivos a los clientes actuales por referir a amigos y familiares para que se unan al servicio. Esto podría incluir descuentos en la factura, créditos en la cuenta o incluso regalos físicos.

Incentivar a los clientes actuales a que sigan refiriendo a nuevos clientes incluso después de la primera recomendación exitosa. Esto puede hacerse ofreciendo recompensas adicionales o descuentos a medida que acumulan más referidos.

4. Programas de Actualización Contrato

Crear programas que permitan a los clientes actualizar sus planes o dispositivos con facilidad a medida que sus necesidades cambian, sin penalizaciones excesivas.

Los programas deben ser personalizados. Ofrecer servicios o planes que se ajusten a sus necesidades específicas aumentará su satisfacción.

Impacto a partir de los patrones de fuga detectados

1. Programas de Lealtad

Crear un programa de lealtad en el que los clientes acumulen puntos o recompensas por cada mes que permanezcan como cliente. Estos puntos pueden canjearse por descuentos, regalos o servicios adicionales.

Este ítem ataca al 36% de los clientes fugados con una duración de contrato menor a 4 meses, y según nuestro modelo con este programa de lealtad afectara al 14% de la base, equivalente a retener un monto de MM\$8 por la facturación mensual que se dejaba de percibir por los clientes fugados.

2. Descuentos a Largo Plazo

Ofrecer descuentos adicionales a aquellos clientes que renueven su contrato anual.

El 80% de los fugados no tienen contrato anual. Al ser el ítem con mayor impacto tiene afectando al 40% de la base. Ofreciendo mejor experiencia y un descuento anual de 10% en contratos anuales equivalente a un costo como empresa de MM\$6, y el beneficio equivalente a MM\$24 de renta mensual retenida.

3. Programa de Recompensas por Referidos

Ofrecer incentivos a los clientes actuales por referir a amigos y familiares para que se unan al servicio. Esto podría incluir descuentos en la factura, créditos en la cuenta o incluso regalos físicos.

Los clientes que generan 2 o más recomendaciones, tienen una fuga menor 6%. Por lo tanto, este programa está enfocado mejorar el servicio al cliente y optimizar los tiempos de respuesta de requerimientos de clientes, ya se de postventa o reclamos.

4. Programas de Actualización Contrato

Crear programas que permitan a los clientes actualizar sus planes o dispositivos con facilidad a medida que sus necesidades cambian, sin penalizaciones excesivas.

El 19% de los fugados tienen una renta mensual mayor a \$36.000, actualizar un contrato equivalente a -20% a este cliente significa un costo de MM\$11,9, sin embargo, por retención se estima abarcar un 10% de la base que equivale a una renta mensual de MM\$4,8, lo que significa recuperar en 2,5 meses.

Modelo Predictivo

Fuga de Clientes en Telefonía

Proyecto 1, Ciencia de Datos y sus Aplicaciones

03.10.2023