ESCUELA DE INGENIERÍA
FACULTAD DE INGENIERÍA

EDUCACIÓN
PROFESIONAL

Diplomado en Big Data y Ciencias de Datos

Minería de Datos

Matrices de Confusión

Educación Profesional - Escuela de Ingeniería UC

Sebastián Raveau

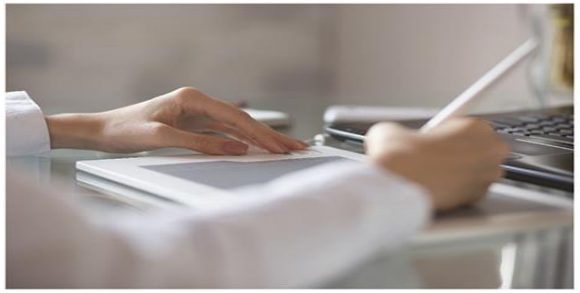


Matriz de confusión

Dos resultados: **positivo** y **negativo**

A cuál corresponde cada posible resultado se define según el contexto de aplicación

		Referencia	
		Positivo	**Negativo**
Predicho	**Positivo**	**TP** Verdadero Positivo	**FP** Falso Positivo
	Negativo	**FN** Falso Negativo	**TN** Verdadero Negativo

Ejemplo

Modelo KNN de riesgo crediticio, con K = 3
(visto en la sesión 5 del curso)

En este caso:

Positivo = Mala evaluación de riesgo

Negativo = Buena evaluación de riesgo

Se pueden definir al revés, simplemente cambia la interpretación de algunos indicadores

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Exactitud (*accuracy*)

Corresponde a la tasa de clasificación correcta

$$A = \frac{TP+TN}{TP+FP+FN+TN}$$

En nuestro ejemplo:

$$A = \frac{22+142}{22+28+58+142} = 0{,}656$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Tasa de No Información (*no information rate*)

Corresponde a la tasa mayoritaria

(depende de los datos, no del modelo)

$$NIR = \frac{\max\{TP+FN;FP+TN\}}{TP+FP+FN+TN}$$

En nuestro ejemplo:

$$NIR = \frac{28+142}{22+28+58+142} = 0{,}680$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Sensibilidad (*sensitivity*)

Corresponde a la tasa de clasificación correcta de los datos positivos

$$Se = \frac{TP}{TP+FN}$$

En nuestro ejemplo:

$$Se = \frac{22}{22+58} = 0{,}275$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Especificidad (*specificity*)

Corresponde a la tasa de clasificación correcta de los datos negativos

$$Sp = \frac{\text{TN}}{\text{TN+FP}}$$

En nuestro ejemplo:

$$Sp = \frac{142}{142+28} = 0{,}835$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Exactitud Balanceada (*balanced accuracy*)

Corresponde al promedio entre sensibilidad y especificidad

$$BA = \frac{Se + Sp}{2}$$

En nuestro ejemplo:

$$BA = \frac{0{,}275 + 0{,}835}{2} = 0{,}555$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Prevalencia (*prevalence*)

Corresponde a la tasa de datos positivos

(depende de los datos, no del modelo)

$$P = \frac{\text{TP+FN}}{\text{TP+FP+FN+TN}}$$

En nuestro ejemplo:

$$P = \frac{22+58}{22+28+58+142} = 0{,}320$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Valor de Predicción Positiva (*pos pred value*)

Corresponde a la tasa de predicciones positivas clasificadas correctamente

$$PPV = \frac{TP}{TP + FP}$$

En nuestro ejemplo:

$$PPV = \frac{22+28}{22+28} = 0{,}440$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Valor de Predicción Negativa (*neg pred value*)

Corresponde a la tasa de predicciones negativas clasificadas correctamente

$$NPV = \frac{TN}{TN + FN}$$

En nuestro ejemplo:

$$NPV = \frac{142}{142+58} = 0{,}710$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Tasa de Detección (*detection rate*)

Corresponde a la tasa de verdaderos positivos, sobre el total de datos

$$DR = \frac{\text{TP}}{\text{TP+FP+FN+TN}}$$

En nuestro ejemplo:

$$DR = \frac{22}{22+28+58+142} = 0{,}088$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Indicadores: Prevalencia de Detección (*detection prevalence*)

Corresponde a la tasa de positivos predichos, sobre el total de datos

$$DP = \frac{\text{TP+FP}}{\text{TP+FP+FN+TN}}$$

En nuestro ejemplo:

$$DP = \frac{22+28}{22+28+58+142} = 0{,}200$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Estadígrafos: Exactitud al azar (*random accuracy*)

Corresponde a la exactitud de un modelo que clasifica al azar

$$p_T = \frac{\text{TP+FN}}{\text{TP+FP+FN+TN}}; p_N = \frac{\text{TP+FP}}{\text{TP+FP+FN+TN}}$$

$$RA = p_T \cdot p_N + \left(1 - p_T\right) \cdot \left(1 - p_N\right)$$

En nuestro ejemplo:

$$RA = 0{,}320 \cdot 0{,}200 + 0{,}680 \cdot 0{,}800 = 0{,}608$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142

Estadígrafos: Kappa

Compara la exactitud del modelo con la exactitud al azar

$$\kappa = \frac{A - RA}{1 - RA}$$

En nuestro ejemplo:

$$\kappa = \frac{0{,}656 - 0{,}608}{1 - 0{,}608} = 0{,}122$$

		Referencia	
		Positivo	Negativo
Predicho	Positivo	TP 22	FP 28
	Negativo	FN 58	TN 142